Informe de EDA Técnico – Corpus AG News

Pre-entrega Módulo 2 · Data Science III: NLP & Deep Learning · TOLEDO, Alejandro Nicolás

0. Dataset y splits

Se utiliza el dataset provisto **AG News** (4 clases: World, Sports, Business, Sci_Tech), cargado con cargar_dataset.py. Train: **8.000** documentos; test: **2.000**. Sin nulos (0) ni duplicados (0). Todo el EDA (frecuencias, N-gramas, percentiles) se calcula **exclusivamente sobre train**; al test sólo se le aplica la misma función preprocess_text, sin ajustar nada sobre él, para evitar data leakage.

1. Pasos de preprocesamiento aplicados

Función **preprocess_text(text)** = limpieza Regex → normalización → lematización SpaCy (en_core_web_sm, parser y NER desactivados) → filtrado de stop-words con lista de excepciones. Estrategia de tokenización: **word-level** (SpaCy), coherente con el baseline TF-IDF del Módulo 3; para el Módulo 4 el texto se re-tokenizará con el tokenizer subword de DistilBERT.

#	Paso	Detalle / Ruido detectado en train crudo
1	Entidades HTML rotas	'#39;' → apóstrofo y 'quot;' / '&' eliminados (2,174 docs con entidades sin '&')
2	Tags HTML	Regex <[^>]+> (control de calidad: 0 docs con tags)
3	Boilerplate de tickers	'(XXX.N: Quote, Profile, Research)' de Reuters (65 docs)
4	Agencias / datelines	'(AP)', '(Reuters)', 'AP - ', 'AFP - '... (1.644 con tag, 967 con dateline)
5	URLs y e-mails	http, www, dominios .com/.net/.org (244 docs)
6	Normalización	lowercase; remoción de números, puntuación y símbolos; colapso de espacios
7	Lematización	SpaCy: 'announced'→'announce', 'prices'→'price', "n't"→'not'
8	Stop-words	Lista SpaCy (326) MENOS {no, not, nor, never, against, up, down, off, over}: negación y direccionalidad tienen carga semántica (ej. 'shares up', 'win over')
9	Tokens residuales	se descartan tokens de 1 carácter

Ejemplo:

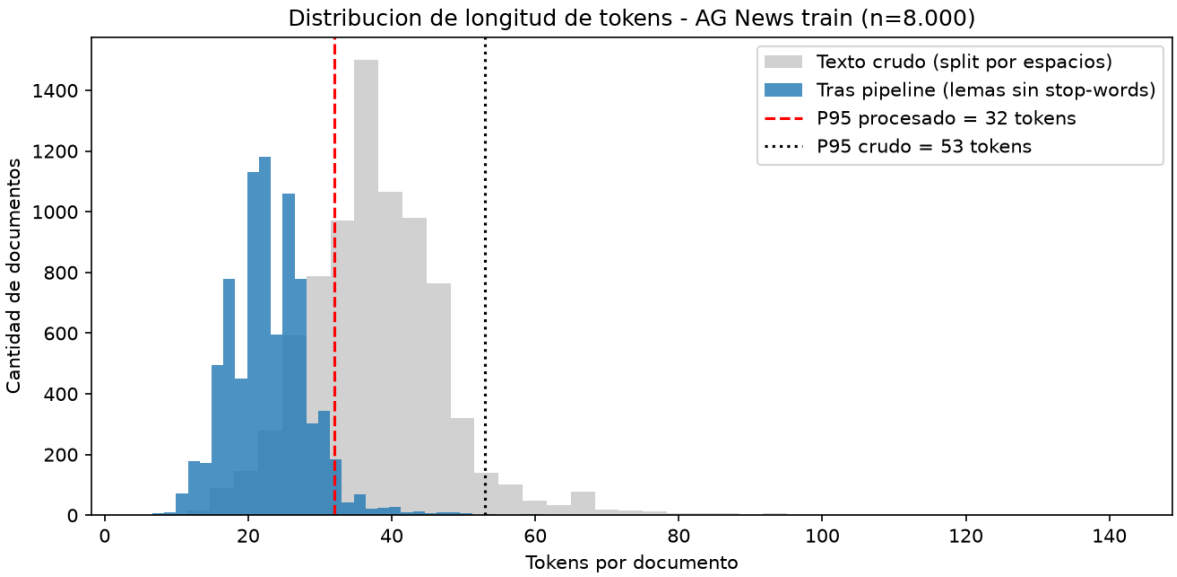
Crudo: Red Hat Appoints New CFO. September 2, 2004 -- (WEB HOST INDUSTRY REVIEW) -- Linux distributor Red Hat (redhat.com) announced on Thursday that it has appointed Charles E. Peters, Jr.

Procesado: red hat appoint new cfo september linux distributor red hat announce thursday appoint charles peters jr

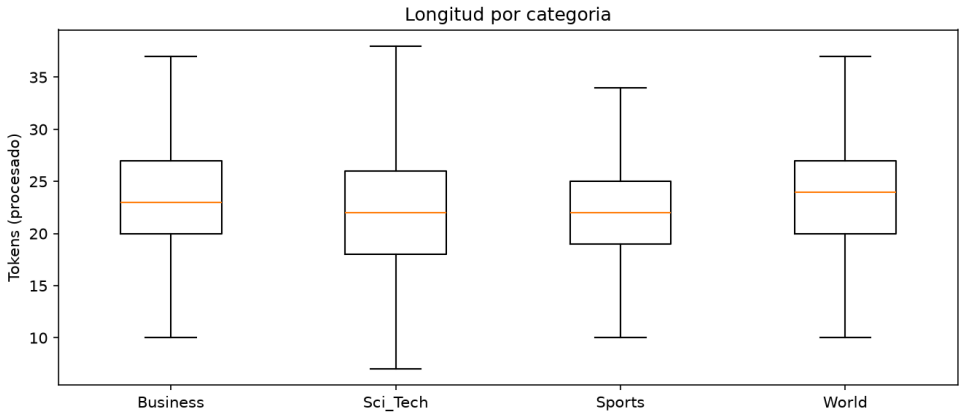
---

Impacto global: Los tokens pasan de 284.093 (lematizados, con stop-words) a 183.689 (−35,3%). Vocabulario final: 16.859 lemas, de los cuales 6.724 (40%) son hapax (frecuencia 1).

2. Distribución de longitud de tokens



Texto crudo: media 37,96 palabras, mediana 38, máx. 142, P95 = **53**. Tras el pipeline: media 22,96, mediana 23, rango 5–71, **P95 = 32 tokens**, sin documentos vacíos. La distribución es unimodal, compacta y con cola derecha corta: el 95% de las noticias cabe en una secuencia muy corta. Para DistilBERT, se utilizará el texto original con limpieza mínima y se determinará max_length calculando el percentil 95 de las longitudes obtenidas mediante su tokenizador específico. Este procedimiento permitirá establecer un límite de secuencia basado en la representación real del modelo y estimar el porcentaje de documentos que requerirá truncamiento.



Medianas por clase: Business 23, Sci_Tech 22, Sports 22, World 24. La longitud no discrimina clases, por lo que el modelo deberá apoyarse en el contenido léxico.

3. Top 20 bi-gramas y tri-gramas (CountVectorizer, scikit-learn)

#	Bi-grama	Frec.	Tri-grama	Frec.
1	new york	419	new york stock	37
2	oil price	197	boston red sox	37
3	united states	167	high oil price	27
4	prime minister	139	prime minister ariel	26
5	red sox	98	minister ariel sharon	25
6	san francisco	96	state colin powell	22
7	los angeles	96	secretary state colin	22
8	president bush	93	president vladimir putin	21
9	victory over	90	new york yankees	21
10	year old	88	president george bush	21
11	win over	75	security exchange commission	20
12	mobile phone	72	crude oil price	20
13	wall street	71	international space station	18
14	microsoft corp	70	prime minister tony	17
15	world cup	69	minister tony blair	17
16	chief executive	67	los angeles dodger	16
17	european union	65	st louis cardinal	16
18	kill people	65	initial public offering	16
19	year ago	63	mart stores inc	15
20	world large	60	osama bin laden	15

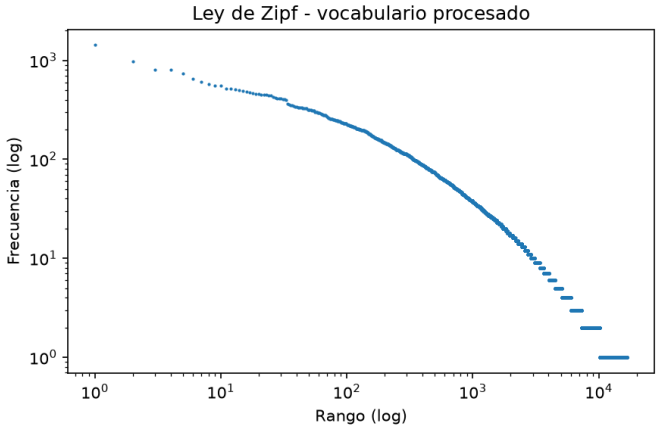
Interpretación. (a) **Calidad de limpieza:** no aparecen tags HTML, entidades ('quot', '39'), nombres de agencias ni el boilerplate 'quote profile research', que sí dominaban una primera versión del pipeline. (b) **Entidades multi-palabra:** la mayoría son nombres propios (new york, los angeles, osama bin laden, international space station) que una representación unigram fragmenta; justifica usar ngram_range=(1,2) en TF-IDF. (c) **Señal de clase clara:** World (prime minister ariel sharon, colin powell, vladimir putin, european union, kill people), Sports (red sox, new york yankees, world cup, victory/win over), Business (oil price, wall street, security exchange commission, initial public offering, new york stock) y Sci_Tech (mobile phone, microsoft corp, international space station). (d) **Valor de las excepciones de stop-words:** 'victory over' y 'win over' sobreviven sólo porque 'over' se preservó, y son marcadores típicos de Sports. (e) Corpus fechado (2004): bush, sharon, powell; anticipa sesgo temporal.

4. Top 50 palabras y control de stop-words

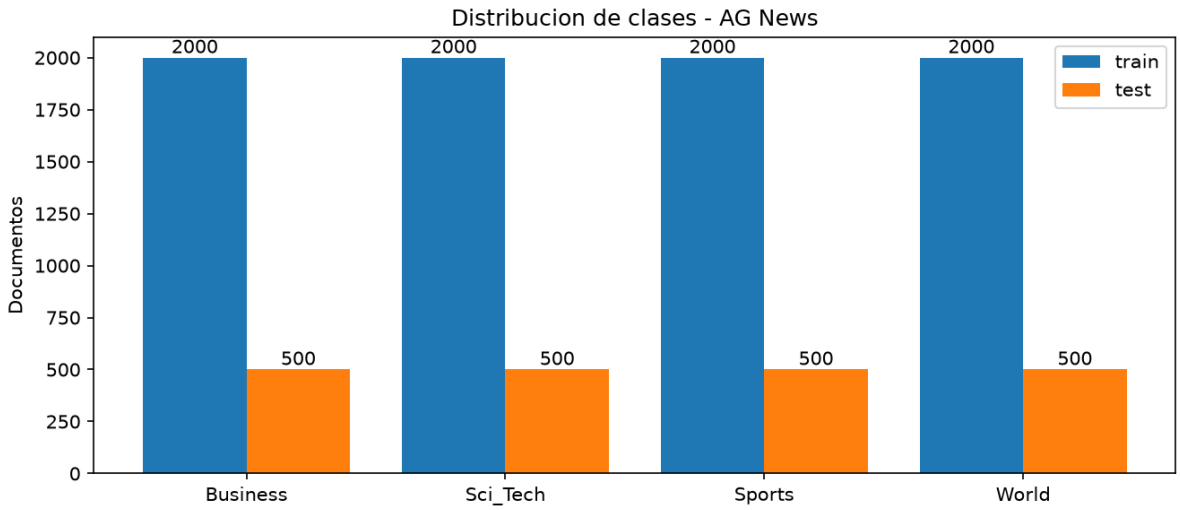
Entre las 50 palabras más frecuentes del corpus procesado aparecen cinco excepciones de la lista de stop-words conservadas deliberadamente: not, over, up, against y no.

#	Palabra	Frec.	#	Palabra	Frec.	#	Palabra	Frec.
1	new	1433	18	price	465	35	open	358
2	year	969	19	million	461	36	government	354
3	not	802	20	against	454	37	security	354
4	over	802	21	inc	452	38	season	347
5	up	731	22	time	447	39	corp	341
6	company	650	23	microsoft	446	40	group	341
7	world	608	24	plan	441	41	rise	335
8	win	579	25	iraq	440	42	team	332
9	game	552	26	yesterday	424	43	people	332
10	report	551	27	york	419	44	united	332
11	oil	519	28	day	410	45	end	329
12	monday	518	29	lead	409	46	month	329
13	wednesday	505	30	president	409	47	share	329
14	thursday	502	31	kill	403	48	state	325
15	tuesday	495	32	high	401	49	stock	317
16	friday	480	33	no	395	50	market	316
17	week	473	34	official	364			

Se observan días de la semana (monday…friday), 'yesterday', 'year', 'report': vocabulario periodístico transversal a las 4 clases y de bajo poder discriminativo. No se eliminan manualmente: TF-IDF (IDF bajo) los penalizará y en el Transformer aportan contexto. **El gráfico log-log confirma la Ley de Zipf:** pocos términos concentran la masa y una cola larga de hapax.



5. Distribución de clases



Distribución de clases. Tanto el conjunto de entrenamiento (*train*) como el de prueba (*test*) presentan una distribución perfectamente balanceada, con 2.000 y 500 documentos por categoría, respectivamente. Esta uniformidad evita la necesidad inicial de aplicar técnicas de compensación de clases, como class_weight o sobremuestreo (*oversampling*). Asimismo, permite utilizar *accuracy* y *F1-macro* como métricas complementarias para evaluar el desempeño del modelo, ya que ambas otorgan una consideración equitativa a las cuatro categorías. Como referencia, un clasificador aleatorio que asigne probabilidades iguales a las cuatro clases tendría una *accuracy* esperada del 25%.

6. Conclusión sobre la preparación del dato

Desafíos en el texto. El corpus no está tan limpio como aparenta: el EDA reveló entidades HTML rotas sin '&' ('#39;', 'quot;') en aproximadamente, el 27% de las noticias, firmas de agencia ('(AP)', 'Reuters - ') y boilerplate de tickers ('Quote, Profile, Research'). En una primera iteración, 'quot', 'ap' y 'quote profile research' aparecían entre los términos y N-gramas más frecuentes; un modelo podría haber aprendido la agencia en lugar del tema. El pipeline los elimina con Regex específicas antes de normalizar, de esta manera: Los principales n-gramas ya no presentan los patrones de ruido identificados previamente. El segundo desafío es la cola larga: El filtrado de stop-words y la eliminación de tokens residuales de un carácter reducen el corpus de 284.093 a 183.689 tokens (−35,3%). Por otra parte, aproximadamente el 40% del vocabulario final corresponde a hapax (términos que aparecen una sola vez). Se filtran stop-words, pero preservando negaciones y partículas direccionales ('not', 'no', 'up', 'over', 'against'), que aportan señal ('win over' en Sports, 'shares up' en Business). La lematización reduce la dispersión morfológica; los hapax restantes se controlarán con min_df en TF-IDF y con subwords en el Transformer.

Longitud. Documentos cortos y homogéneos (P95 = 32 tokens procesados, 53 palabras crudas): max_len=32 para modelos word-level y (aprox.) 64–80 subtokens para DistilBERT, con truncado mínimo y poco padding.

Clases. Balance perfecto (2.000/500 por clase en train/test): No se requieren inicialmente técnicas de reponderación de clases. Se utilizarán accuracy y F1-macro como métricas complementarias, ya que permiten evaluar tanto el rendimiento global como el desempeño equilibrado entre las cuatro categorías.

Conclusión. El corpus queda listo: sin nulos ni duplicados, sin ruido en los N-gramas, con max_len justificado y splits respetados (EDA sólo sobre train). Se exporta la columna 'clean' para TF-IDF (Módulo 3), mientras que el texto

original con limpieza mínima se reserva para el Transformer (Módulo 4), que se beneficia de stop-words y mayúsculas para el contexto.